

Projekt, UPA 2. část: Příprava dat a ich popisná charakteristika

Matúš Biely *xbiely00@stud.fit.vutbr.cz*
Ondřej Misar *xmisar01@stud.fit.vutbr.cz*
Samuel Kuchta *xkucht11@stud.fit.vutbr.cz*

November 2023

Obsah

1	Exploratívna analýza	1
1.1	Atribúty dátovej sady	1
1.2	Rozloženie hodnôt	3
1.3	Detekcia odľahlých hodnôt	7
1.4	Analýza chýbajúcich hodnôt	8
1.5	Korelačná analýza	9
2	Príprava dát	11
2.1	Odstránenie irelevantných atribútov	11
2.2	Odstránenie chýbajúcich hodnôt	11
2.3	Spracovanie odľahlých hodnôt	11
2.4	Diskretizácia numerických atribútov	11
2.5	Transformácia kategorických atribútov	12

Zoznam obrázkov

1	Popisná tabuľka numerických atribútov	2
2a	Popisná tabuľka kategorických atribútov	2
2b	Popisná tabuľka kategorických atribútov - pokračovanie	3
3	Histogram podľa štúdijských odborov	3
4	Huslový graf pre úroveň stresu v závislosti na odbore	4
5	Stĺpcový graf priemerných hodnôt stresu voči diéte v rámci odboru	4
6	Histogram úrovne depresie pre jednotlivé odbory	5
7	Krabicový graf úrovne depresie pre jednotlivé odbory v závislosti na chronických chorobách	5
8	Histogram úrovne úzkosti pre jednotlivé odbory	6
9	Stĺpcový graf úrovne úzkosti pre počet zapísaných kreditov	6
10a	Krabicový graf pre vek jednotlivca	7
10b	Krabicový graf pre GPA jednotlivca	7
10c	Krabicový graf pre počet zapísaných kreditov jednotlivca	8
11	Chýbajúce hodnoty	8
12	Korelačná matica	9
13	Matica bodových grafov	10

Zoznam tabuliek

1	Prehľad najčastejších hodnôt numerických atribútov	2
---	--	---

1 Exploratívna analýza

Zvolená dátová sada: **Students Mental Health Assessments**

Dostupná z URL: <https://www.kaggle.com/datasets/sonia22222/students-mental-health-assessments>

1.1 Atribúty dátovej sady

Age: Vek jednotlivca. Jedná sa o numerický atribút v rozsahu 18 – 35 rokov.

Course: Zameranie jednotlivca. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Medical“, „Law“, „Engineering“, „Computer Science“, „Business“ a „Others“.

Gender: Atribút určujúci pohlavie jednotlivca. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Male“ a „Female“.

CGPA: Štúdijný priemer jednotlivca. Numerický atribút v rozsahu 1 – 4 vo forme desatinného čísla.

Stress_Level: Hodnota reprezentujúca úroveň stresu jednotlivca. Jedná sa o numerický atribút nadobúdajúci hodnoty 0 – 5.

Depression_Score: Hodnota reprezentujúca úroveň depresie jednotlivca. Jedná sa o numerický atribút nadobúdajúci hodnoty 0 – 5.

Anxiety_Score: Hodnota reprezentujúca úroveň úzkosti jednotlivca. Jedná sa o numerický atribút nadobúdajúci hodnoty 0 – 5.

Sleep_Quality: Kvalita spánku jednotlivca. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Poor“, „Average“ a „Good“.

Physical_Activity: Úroveň fyzickej aktivity jednotlivca. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Low“, „Moderate“ a „High“.

Diet_Quality: Kvalita diéty jednotlivca. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Poor“, „Average“ a „Good“.

Social_Support: Úroveň spoločenskej podpory pre jednotlivca. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Low“, „Moderate“ a „High“.

Relationship_Status: Typ rodinného stavu, v akom sa jednotlivec nachádza. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Single“, „In a Relationship“ a „Married“.

Substance_Use: Frekvencia používania omamných látok jednotlivcom, ako napríklad alkohol, cigarety, či iné drogy. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Never“, „Occasionally“ a „Frequently“.

Counseling_Service_Use: Frekvencia využívania poradenských služieb jednotlivcom. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Never“, „Occasionally“ a „Frequently“.

Family_History: Atribút označujúci, či sa v rodine jednotlivca v minulosti vyskytli mentálne choroby. Jedná sa o kategorický atribút nadobúdajúci hodnoty „No“ a „Yes“.

Chronic_Illness: Atribút označujúci, či jednotlivec trpí nejakou chronickou chorobou. Jedná sa o kategorický atribút nadobúdajúci hodnoty „No“ a „Yes“.

Financial_Stress: Hodnota reprezentujúca úroveň finančnej tiesne jednotlivca. Jedná sa o numerický atribút nadobúdajúci hodnoty 0 – 5.

Extracurricular_Involvement: Atribút označujúci frekvenciu, s akou sa jednotlivec zúčastňuje mimoškolských aktivít. Jedná sa o kategorický atribút nadobúdajúci hodnoty „Low“, „Moderate“ a „High“.

Semester_Credit_Load: Hodnota reprezentujúca počet kreditov, ktoré má jednotlivec zapísané v danom semestri. Jedná sa o numerický atribút nadobúdajúci hodnoty 15 – 30.

Residence_Type: Typ bývania, v akom sa jednotlivec nachádza počas štúdia. Jedná sa o kategorický atribút nadobúdajúci hodnoty „On-Campus“, „Off-Campus“ a „With Family“.

	Age	CGPA	Stress_Level	Depression_Score	Anxiety_Score	Financial_Stress	Semester_Credit_Load
count	7022.000000	7010.00000	7022.000000	7022.000000	7022.000000	7022.000000	7022.000000
mean	23.003418	3.49127	2.427941	2.254486	2.300484	2.453005	22.010538
std	3.853978	0.28742	1.638408	1.625193	1.624305	1.708995	4.358380
min	18.000000	2.44000	0.000000	0.000000	0.000000	0.000000	15.000000
25%	20.000000	3.29000	1.000000	1.000000	1.000000	1.000000	18.000000
50%	22.000000	3.50000	2.000000	2.000000	2.000000	2.000000	22.000000
75%	25.000000	3.70000	4.000000	3.000000	4.000000	4.000000	26.000000
max	35.000000	4.00000	5.000000	5.000000	5.000000	5.000000	29.000000

Obr. 1: Popisná tabuľka numerických atribútov

Na obrázku 1 môžeme vidieť rôzne štatistické parametre pre jednotlivé numerické atribúty zo zvolenej dátovej sady. V dátovej sade sa nachádza celkovo 7022 záznamov čo znamená, že v prípade ak je pre nejaký parameter hodnota **count** nižšia, niektoré záznamy nemajú vyplnený daný atribút. Zvyšné hodnoty **mean**, **std**, **min** a **max** predstavujú **strednú hodnotu**, **štandardnú odchýlku**, **minimálnu** a **maximálnu hodnotu** v tomto poradí. Parametre **25%**, **50%** a **75%** predstavujú kvartily, čo znázorňuje, koľko percent z celkového počtu záznamov sa nachádza pod danou hodnotou.

Názov atribútu	Najčastejšia hodnota	Počet výskytov	% z celku
Age	21	777	11,07%
Stress_Level	3	1405	20,01%
Depression_Score	3	1388	19,77%
Anxiety_Score	3	1429	20,35%
Financial_Stress	0	1230	17,52%
Semester_Credit_Load	27	513	7,31%

Tabuľka 1: Prehľad najčastejších hodnôt numerických atribútov

Nakoľko všetky numerické atribúty s výnimkou **CGPA** predstavujú celočíselné hodnoty, nie je z tejto tabuľky na obrázku 1 jasne vidieť, ktoré hodnoty sa pre jednotlivé atribúty vyskytujú najčastejšie. Preto je tento prehľad detailnejšie ukázaný v tabuľke 1.

	Course	Gender	Sleep_Quality	Physical_Activity	Diet_Quality	Social_Support	Relationship_Status	Substance_Use
count	7022	7022	7022	7022	7022	7022	7022	7007
unique	6	2	3	3	3	3	3	3
top	Medical	Male	Good	Moderate	Average	Moderate	Single	Never
freq	2105	3547	3589	3521	4268	3470	3574	5903

Obr. 2a: Popisná tabuľka kategorických atribútov


	Counseling_Service_Use	Family_History	Chronic_Illness	Extracurricular_Involvement	Residence_Type
count	7022	7022	7022	7022	7022
unique	3	2	2	3	3
top	Never	No	No	Moderate	On-Campus
freq	4263	4866	6678	3440	2815

Obr. 2b: Popisná tabuľka kategorických atribútov - pokračovanie

Obdobne ako pre numerické atribúty si v tabuľkách na obrázkoch 2a a 2b môžeme prehľadne ukázať určité štatistické parametre pre kategorické atribúty. Význam parametru **count** zostáva rovnaký ako pri numerických atribútoch. Parameter **unique** určuje počet unikátnych hodnôt, ktoré daný kategorický atribút nadobúda. Parameter **top** zobrazuje najčastejšie sa vyskytujúcu hodnotu pre daný atribút, s čím súvisí aj parameter **freq**, ktorý ukazuje počet výskytov tejto najčastejšie vyskytujúcej sa hodnoty.

1.2 Rozloženie hodnôt

V použitej dátovej sade sa vyskytujú atribúty stresu, depresie a úzkosti. Práve pre tieto atribúty budeme zobrazovať, akým spôsobom sa budú meniť v závislosti na zvyšných atribútoch. Vďaka tomu budeme vedieť vhodne zvoliť atribúty, ktoré majú význam pre následnú dolovaciu úlohu.



Obr. 3: Histogram podľa štúdijských odborov

V grafe na obrázku 3 si môžeme všimnúť, že najväčšie zastúpenie v tejto dátovej sade predstavujú študenti študujúci odbor medicíny. Odbory preto budú predstavovať dôležitý faktor, ktorý bude treba zohľadniť pri práci s úrovňami stresu, depresie a úzkosti.


Postupne prejdeme, akým spôsobom zvyšné atribúty ovplyvňujú stres, depresiu a úzkosť.

Stres

Najskôr sa pozrieme na to, akým spôsobom ovplyvňuje úroveň stresu odbor, ktorý študent študuje.


V grafe na obrázku 4 je možné vidieť, že hustota väčšieho stresu je výraznejšie zoskupená okolo vyšších hodnôt pre študentov medicíny v porovnaní s inými odbormi.

Na základe toho je zjavné, že odbor zohráva dôležitú rolu v úrovni stresu.



Obr. 4: Huslový graf pre úroveň stresu v závislosti na odbore

Z grafu na obrázku 5 je možné vidieť, ako atribút diéty ovplyvňuje priemernú úroveň stresu v rámci jednotlivých odborov. Na základe grafu je možné určiť, že pre niektoré odbory ovplyvňuje kvalita diéty úroveň stresu spôsobom, kedy napríklad pre biznis dobrá diéta v priemere zvyšuje stres a naopak pre medicínu dobrá diéta priemerný stres znižuje.




Obr. 5: Stĺpcový graf priemerných hodnôt stresu voči diéte v rámci odboru

Depresia


V druhej časti sa pozrieme na depresiu a to, akým spôsobom je úroveň depresie významná v rámci jednotlivých odborov.

V grafe na obrázku 6 je možné vidieť, že študenti s vyššou úrovňou depresie 4 a 5 predstavujú najpočetnejšiu skupinu v odbore informačných technológií. Aj napriek tomu, že študenti medicíny sú najväčšia skupina celkovo, pre úrovne depresie 4 a 5 je ich menej ako študentov informačných technológií. Z toho nám vyplýva, že študenti, ktorí by sami seba ohodnotili, že sú vo výraznej depresii je najviac práve u študentov študujúcich informačné technológie.



Obr. 6: Histogram úrovne depresie pre jednotlivé odbory

V grafe na obrázku 7 je možné vidieť, že atribút chronickej choroby ovplyvnil úroveň depresie prakticky pre všetky odbory. Pre niektoré odbory prítomnosť chronickej choroby zvyšuje úroveň depresie ako napríklad pre strojárňu alebo „Others“, zatiaľ čo pri iných ju znižuje ako napríklad pre medicínu, právo či informačné technológie.




Obr. 7: Krabicový graf úrovne depresie pre jednotlivé odbory v závislosti na chronických chorobách

Úzkosť


Pre posledný sledovaný atribút úzkosti sa opäť pozrieme na rozdelenie v rámci jednotlivých odborov, a ako je ovplyvnený inými atribútmi.

Na obrázku 8 si môžeme všimnúť podobný jav ako sme videli pri depresií, kedy aj napriek tomu, že medicína je celkovo najväčšia skupina, tak pre vysoké úrovne úzkosti 4 a 5 predstavujú študenti práva najpočetnejšie skupiny.



Obr. 8: Histogram úrovne úzkosti pre jednotlivé odbory

V grafe na obrázku 9 je možné vidieť, že počet zapísaných kreditov má od určitej hranice priamy dopad na úzkosť jednotlivca. V našom prípade je táto hranica 23 zapísaných kreditov, kedy od tejto hranice je priemerná úzkosť už iba vyššia.




Obr. 9: Stĺpcový graf úrovne úzkosti pre počet zapísaných kreditov


1.3 Detekcia odľahlých hodnôt

Zisťovanie odľahlých hodnôt vychádzalo zo skúmania dát v predchádzajúcej sekcii. Odľahlé hodnoty môžeme zisťovať iba pre numerické atribúty, ktorých sa v našej dátovej sade nachádza 7. Atribúty **Stress_Level**, **Depression_Score**, **Anxiety_Score** a **Financial_Stress** nadobúdajú celočíselné hodnoty od 0 do 5 a predošlou analýzou za použitia napríklad krabicových grafov sme zistili, že rozloženie týchto hodnôt nebude obsahovať žiadne odľahlé hodnoty. Toto bolo už zjavné napríklad z krabicového grafu na obrázku 7, na ktorom bolo jasne vidieť, že kvartily týchto atribútov pokrývajú celú množinu nadobúdaných hodnôt. Obdobne by sme si to vedeli ukázať aj pre **Stress_Level**, **Anxiety_Score** a **Financial_Stress**. Pre tieto atribúty by sme si vedeli zobraziť podobné krabicové grafy ako budú nasledovať na obrázkoch 10c, 10a a 10b videli by sme, že tu nebudú existovať žiadne odľahlé hodnoty.


Preto sme hľadali odľahlé hodnoty pre zvyšné numerické atribúty. Menovite sa jedná o atribúty **CGPA**, **Age** a **Semester_Credit_Load**. Najskôr sme sa pozreli na krabicové grafy pre tieto atribúty, na ktorých je možné vidieť, či tieto atribúty obsahujú odľahlé hodnoty.



Obr. 10a: Krabicový graf pre vek jednotlivca



Obr. 10b: Krabicový graf pre GPA jednotlivca



Obr. 10c: Krabicový graf pre počet zapísaných kreditov jednotlivca

Z krabicových grafov na obrázkoch 10a a 10b vidíme, že vek a GPA obsahujú odľahlé hodnoty. Na obrázku 10c je naopak viditeľné, že počet zapísaných kreditov neobsahuje odľahlé hodnoty.

Pre vyhľadávanie odľahlých hodnôt použijeme metódu „Z-score“, kde následne pre všetky záznamy dáť vypočítame túto hodnotu samostatne pre Vek a GPA, pričom táto hodnota vyjadruje, o koľko štandardných odchýlok je táto hodnota vzdialená od priemeru. V prípade, že by hodnota „Z-score“ bola 0, tak by sa jednalo presne o priemer. Okolo priemeru sa sa vieme pohybovať o 3σ , čo nám obsiahne 99.7% hodnôt. Preto ak sa hodnota pohybuje mimo intervalu $<-3;3>$, tak bude táto hodnota považovaná za odľahlú.

1.4 Analýza chýbajúcich hodnôt

Pre analýzu chýbajúcich hodnôt sme použili funkciu „isna“, ktorá nám vráti tabuľku na obrázku 11, kde môžeme vidieť, že chýbajú niektoré hodnoty pre **Substance_Use** a **CGPA**. Pre zvyšné hodnoty numerických atribútov sme mohli už v predchádzajúcej sekcii vidieť, že tieto atribúty neobsahujú hodnoty, ktoré by nedávali zmysel pre daný atribút, ako napríklad vek 0 rokov, prípadne počet zapísaných kreditov 0, či GPA 0 a podobne.

```

Substance_Use      15
CGPA               12
Age                0
Relationship_Status 0
Semester_Credit_Load 0
Extracurricular_Involvement 0
Financial Stress    0
Chronic_Illness     0
Family_History      0
Counseling_Service_Use 0
Social_Support      0
Course              0
Diet_Quality        0
Physical_Activity    0
Sleep_Quality       0
Anxiety_Score       0
Depression_Score    0
Stress_Level        0
Gender              0
Residence_Type      0
dtype: int64


```

Obr. 11: Chýbajúce hodnoty

Pre chýbajúce hodnoty sme si tieto záznamy vypísali, ale nenašli sme žiadne záznamy, kde by chýbali hodnoty zároveň pre **Substance_Use** a **CGPA**.


1.5 Korelačná analýza

Korelačnú analýzu budeme robiť pre všetky numerické atribúty. Pre tieto atribúty dopočítame korelačné koeficienty, za použitia Pearsonovho korelačného koeficientu, ktoré následne zobrazíme pomocou korelačnej matice v podobe tzv. „heatmap“-y. Túto maticu je možné vidieť na obrázku 12, pre všetky dvojice atribútov. Ako si môžeme všimnúť, tak korelácia medzi jednotlivými atribútmi je dosť nízka, kedy sa všetky hodnoty (mimo diagonály) pohybujú okolo nuly.



Obr. 12: Korelačná matica

Koreláciu medzi jednotlivými atribútmi si vieme zobraziť aj za pomoci matice bodových grafov na obrázku 13, ktorá je symetrická voči diagonále.



Obr. 13: Matica bodových grafov

2 Príprava dát

Po analýze dát vieme pokročiť k tomu, aby sme určitým spôsobom tieto dáta pripravili na ďalšie spracovanie.

2.1 Odstránenie irelevantných atribútov

Dolovacia úloha spočíva v klasifikácii stresu, depresie a úzkosti na základe ostatných vhodných atribútov. Pri skúmaní dát sme zistili, že tieto tri atribúty sú rôznym spôsobom ovplyvňované ostatnými atribútmi. Avšak nevideli sme, že by pohlavie, rodinná história alebo rodinný stav nejakým zásadným spôsobom ovplyvňovali stres, depresiu, či úzkosť. Preto sa tieto atribúty pre nás stávajú irelevantnými, a môžeme ich odstrániť z dátovej sady.

2.2 Odstránenie chýbajúcich hodnôt

Ako bolo spomenuté v predchádzajúcej kapitole, naša dátová sada obsahuje dva atribúty s chýbajúcimi hodnotami a to konkrétne **Substance_Use** a **CGPA**.

Odstránenie chýbajúcich hodnôt z dátovej sady vieme dosiahnuť dvoma spôsobmi:

- Zmazanie záznamov s chýbajúcimi hodnotami,
- doplnenie chýbajúcich hodnôt.

Zmazanie záznamov s chýbajúcimi hodnotami

Prvým spôsobom sa zbavíme chýbajúcich hodnôt pre atribút **Substance_Use**. Jedná sa o kategorický atribút a dátová sada obsahuje 15 záznamov s nevyplnenou hodnotou pre tento atribút. Pre takýto relatívne malý obsah chýbajúcich dát kategorického atribútu by nemal byť problém zmazať celé záznamy obsahujúce chýbajúce hodnoty. Chýbajúcu hodnotu kategorického atribútu by bolo možné určitým spôsobom odhadnúť, avšak odstránením malého počtu záznamov dát nestratíme podstatné množstvo informácií, preto ich odstránime celé.

Doplnenie chýbajúcich hodnôt

Druhým spôsobom doplníme chýbajúce hodnoty pre numerický atribút **CGPA**. Opäť sa nejedná o veľké množstvo záznamov, ale v tomto prípade doplníme chýbajúce hodnoty. Ako náhradnú hodnotu použijeme priemer tohoto atribútu.

2.3 Spracovanie odľahlých hodnôt

Ako už bolo ukázané v predchádzajúcej kapitole, atribúty **Age** a **CGPA** obsahovali odľahlé hodnoty. Preto sa ich v tomto kroku zbavíme tým, že ich úplne odstránime z dátovej sady. Odstránenie vykonáme pomocou metódy „Z-score“, ktorá bola podrobnejšie popísaná v sekcii 1.3. Všetky záznamy, ktorých „Z-score“ veku a GPA nie je v intervale $<-3;3>$, odstránime z dátovej sady.

2.4 Diskretizácia numerických atribútov

Diskretizáciu numerických atribútov vykonávame preto, aby sme dátovú sadu pripravili pre použitie algoritmi, ktoré vyžadujú dátovú sadu obsahujúcu výhradne kategorické atribúty.

Pre diskretizáciu numerických atribútov použijeme knižnicu „sklearn“. Rozdelenie intervalu si zvolíme na 5 a použijeme stratégiu „quantile“. Táto stratégia zabezpečí rozdelenie dát tým spôsobom, aby bol v každom intervale rovnaký počet hodnôt.

2.5 Transformácia kategorických atribútov

Kategorické atribúty prevádzame na numerické z obdobného dôvodu ako v predošlej sekcii. Niektoré algoritmy vyžadujú na svojom vstupe výhradne numerické atribúty, a dosť často je potrebné, aby boli tieto hodnoty aj normalizované na interval $<0;1>$. Preto transformujeme našu dátovú sadu v dvoch krokoch:

1. Prevod kategorických atribútov na numerické,
2. normalizácia numerických atribútov.

Prevod kategorických atribútov na numerické

Kategorické atribúty je možné previesť na numerické tým, že rozdelíme všetky tieto atribúty podľa jednotlivých hodnôt, ktoré môžu nadobúdať, pričom pôvodný atribút zanikne a do novovzniknutých atribútov sa uloží hodnota 0 alebo 1 podľa toho, ktorá hodnota bola v pôvodnom atribúte. Za týmto účelom nám slúži funkcia z knižnice „pandas“ s názvom „get_dummies“.

Pre ukážku na príklade si zoberieme atribút **Chronic_Illness**, ktorý môže nadobúdať hodnoty „No“ a „Yes“. Novovzniknuté stĺpce budú mať pomenovanie **Chronic_Illness_No** a **Chronic_Illness_Yes**, zatiaľčo pôvodný atribút **Chronic_Illness** zaniká. V prípade, že pôvodný kategorický atribút určitého záznamu mal označenie „Yes“, tak sa do atribútu **Chronic_Illness_Yes** uloží hodnota 1 a do atribútu **Chronic_Illness_No** sa uloží hodnota 0. Obdobne by to fungovalo aj pre hodnotu „No“.

Normalizácia numerických atribútov

Aktuálne máme všetky atribúty vo forme numerických. Pre normalizáciu hodnôt opäť použijeme knižnicu „sklearn“, a to konkrétne normalizáciu pomocou „MinMax“. To nám hodnoty všetkých atribútov prevedie tak, aby boli v intervale $<0;1>$.