

Odhad hloubky z obrazu

Samuel Kuchta, Marek Bahník

1	1. Zadání	
2	Cílem našeho projektu pro práci s konvolučními neu-	Následně se začaly používat <i>reziduální konvoluční neu-</i>
3	ronovými sítěmi je navrhnout síť pro vytvoření odhadu	<i>ronové sítě</i> (ResNet). Tyto sítě se běžně skládají z
4	hloubkové mapy ve scéně z jednoho obrázku. Jelikož	<i>enkodéru</i> a <i>dekodéru</i> , neboli kontraktivní a expanzivní
5	datové sady, které plánujeme používat, jsou pořízeny	části. Výhodou je, že nemusí obsahovat plně propo-
6	z vozidla, primární účel této sítě je využití v řízení	jenou vrstvu, a tedy může být výpočetně rychlejší.
7	autonomních vozidel na silnici.	Nejprve však byly používány enkodéry, které měly až
8	2. Předchozí přístupy	100 vrstev a opět se tedy stávaly výpočetně náročnými.
9	V této sekci přiblížíme předchozí přístupy, které se pro	Tyto sítě byly trénovány pomocí učení bez učitele, což
10	odhad hloubkové mapy používaly. Tyto přístupy často	mohlo taktéž mít negativní vliv na kvalitu a mohlo
11	pramenit z potřeby hloubkové mapy pro autonomní	zapříčinit následující změny.
12	vozidla a tak jsou i často velmi rychle vyvíjeny. Ne-	
13	jprve byly používány tradiční přístupy a v posledních	Jeden z posledních přístupů cílí na snížení počtu vrstev
14	letech se začalo hojně používat hluboké učení a kon-	v enkodéru a primárně používá jednoduché konvoluční
15	voluční neuronové sítě.	vrstvy a předtrénovaný enkodér. Zároveň využívá tzv.
16	2.1 Tradiční přístupy	<i>skip</i> vrstvy - předává informace o extrahovaných <i>fea-</i>
17	Původní přístupy k odhadu hloubkové mapy spočívaly	<i>tures</i> mezi komplementárními vrstvami z enkodéru do
18	v manuální extrakci tzv. <i>features</i> z obrazu. Také byla	dekodéru. Zároveň se jedná o síť, která je učena s
19	pro odhad hloubky využívána <i>Markovovská náhodná</i>	učitelem na datech obsahující jak originální obrázek,
20	<i>pole</i> . Na toto bylo navázáno převodem scény do 3D	tak jeho hloubkovou mapu jako <i>ground truth</i> . Tento
21	prostoru. Dalším tradičním přístupem k odhadu hloubky	přístup nám sloužil jako inspirace k vývoji naší vlastní
22	je hledání podobnosti ve scéně vůči databázi obrázků	KNN ¹ , která by se měla s tímto problémem potýkat.
23	s anotovanými hloubkovými daty a jejich asociací k	
24	hledané scéně. Všechny tyto přístupy spoléhají na	3. Datové sady
25	ručně stanovené parametry extrahované z obrazu a	
26	tudíž nemusí dobře fungovat, pokud jsou aplikovány	V první části našeho vývoje jsme používali datovou
27	na nová prostředí.	sadu CityScapes . Tato sada obsahuje 25000 RGB
28	2.2 Hluboké učení a neuronové sítě	obrázků pořízených z kamery umístěné na vozidle
29	Jako na mnoho dalších problémů počítačového vidění,	směřující dopředu. Sada k těmto obrázkům zároveň
30	i zde se začalo vyvíjet mnoho konvolučních neuronových	obsahuje jedno-kanálový obrázek s hloubkovou mapou
31	sítí pro odhad hloubky. Nejprve se jednalo o dvě sepa-	daného obrázku. Tyto anotované obrázky budou použity
32	rátní neuronové sítě, kdy první vytvořila hrubý odhad	během trénování sítě jako <i>ground truth</i> .
33	pro globální pohled na scénu a druhá pracovala na vyh-	
34	lazení lokálních oblastí. V roce 2014 se tedy jednalo	V případě, že bychom odhalili, že je potřeba většího
35	o <i>state of the art</i> přístup. Nevýhodou tohoto přístupu	množství obrázků, nebo že by bylo třeba využít síť i v
36	bylo, že byl zakončen plně propojenou vrstvou neu-	jiném prostředí, než z pozice auta, máme v záloze další
37	ronů, která je výpočetně velmi náročná.	datové sady ke kterým se můžeme přiklonit. Jedná se
38		o sady KITTI a NYU .
		KITTI obsahuje necelých 100.000 obrázků. K těmto
		obrázkům je také párován obrázek s hloubkovou mapou
		dané scény. Tyto obrázky jsou také pořízeny z vozidla

¹[Github odkaz na implementaci projektu](#)

78	a tím pádem by cíl sítě zůstal stejný.	
79		
80	NYU obsahuje přibližně jenom 1500 obrázků a an-	
81	otací, ale tyto obrázky pochází z mnoha různých pozic	
82	a situací. Zároveň se běžně používá jako <i>benchmark</i>	
83	pro porovnávání výkonu sítě s ostatními sítěmi.	
84	4. Způsob vyhodnocení	
85	Pro vyhodnocení kvality naší sítě využijeme část již	
86	předem vytvořeného <i>frameworku</i> , který vytvořil Bc.	
87	Samuel Kuchta během své bakalářské práce. ² Díky	
88	tomuto nástroji můžeme jednoduše otestovat, jakým	
89	způsobem různé parametry ovlivňují běh trénování	
90	neuronové sítě a tím pádem dojít k co nejlepšímu mod-	
91	elu.	
92	5. Návrh řešení	
93	Základem našeho řešení bude architektura jednoduché	
94	konvoluční neuronové sítě založená na U-Net nebo	
95	podobné architektuře. Tato architektura prokázala	
96	schopnosti v sémantické segmentaci a může být adap-	
97	tována pro odhad hloubky pomocí změny výstupního	
98	obrázku z segmentační mapy na hloubkovou mapu.	
99	Tento model bude dále trénován pomocí již zmíněných	
100	datových sad a výsledky budou zhodnoceny během	
101	validačního procesu.	
102	6. Následující plány	
103	6.1 Předzpracování dat	
104	Jako předzpracování dat použijeme změnu velikosti	
105	obrázků, normalizaci hodnot pixelů a obrazovou aug-	
106	mentaci pro zrobustnění datové sady.	
107	6.2 Návrh architektury modelu	
108	Dále bude třeba zfinalizovat architekturu sítě, která	
109	bude schopna vypořádat se s odhadem hloubky. To	
110	může obsahovat experimenty s různými variantami	
111	konvolučních sítí, zapojení tzv. <i>skip connections</i> pro	
112	lepší extrakci <i>features</i> , nebo aplikování <i>attention</i> mech-	
113	anizmů pro soustředění na relevantní části obrázku.	
114	6.3 Trénování sítě	
115	Po výběru vhodné architektury je třeba model trénovat.	
116	K tomu bude využita část datové sady pro trénování.	
117	Pro trénování bude využit ADAM optimizer nebo	
118	stochastic gradient descent . Tento proces trénování	
119	bude sledován a v případě potřeby budou hyperparame-	
120	try změněny tak, aby nedošlo k přetrénování.	
	6.4 Evaluace	121
	K evaluaci modelu bude využita další část datové sady	122
	přímo určené k tomuto účelu. K samotné evaluaci	123
	budou použity metriky <i>mean absolute error</i> nebo <i>root</i>	124
	<i>mean square error</i> s výstupním obrázkem a <i>ground</i>	125
	<i>truth</i> obrázkem jako vstupy.	126
	6.5 Ladění a optimalizace	127
	Na základě validačních výsledků budeme dále modi-	128
	fikovat hyperparametry. K tomu budeme experimen-	129
	tovat s technikami, jako např. <i>transfer learning</i> nebo	130
	<i>multi-scale processing</i> pro zlepšení přesnosti modelu.	131
	6.6 Testování	132
	Závěrem zhodnotíme celkovou schopnost generalizace	133
	modelu na sekci testovacích dat z datové sady. Výsledky	134
	můžeme srovnat se <i>state-of-the-art</i> metodami, aby-	135
	chom zhodnotili funkčnost našeho modelu.	136
	6.7 Dokumentace	137
	Celý proces experimentování s architekturami, hyper-	138
	parametry a datovými sadami bude dokumentován.	139
	Tyto znalosti budou následně shrnuty ve výsledném	140
	článku, ve kterém bude srovnání s existujícími modely	141
	a literaturou.	142

²Odkaz na bakalářskou práci