

Čtení č. 1 – Téma čtení

student: Samuel Kuchta, xkucht11

Příprava na čtení

Uveďte alespoň 3 dotazy k danému tématu čtení a případným nejasnostem. Pokud je vše jasné, uveďte věci, které sami pokládáte za nejdůležitější pro pochopení problematiky a ostatní by je určitě měli vědět.

- Je nevyhnutné, aby sa uzol `vsplit` explicitne rozdelil na dve podmnožiny? Nestačilo by nájsť ľavú časť a potom lineárne prejsť pole porovnávaním $\leq$? Očakáva sa pri tom významný rozdiel vo výkonnosti?
- Musí byť skip-list (skip tree) nutne náhodný? Čo ak pri generovaní úrovni nikdy nepadne „hlava“? Nestane sa z toho potom obyčajný lineárny zoznam? Nemôžeme z takej štruktúry jednoducho urobiť deterministický strom s vertikálnymi (hornými) ukazovateľmi?
- Čo by sa stalo, keby sme pri aproximácii najbližších susedov použili PCA (analýzu hlavných komponent)? Ako by aplikácia PCA ovplyvnila presnosť a rýchlosť vyhľadávania?
- Čo presne je GNAT tree, a ako funguje?
- Ak mám menej dát než počet parametrov, nebude optimalizačný algoritmus Nelder-Mead degenerovaný? Napríklad kvôli tomu, že v niektorých dimenziách môže vykonávať len lineárne závislé (degenerované) pohyby v priestore parametrov?

Poznámky ze čtení

Zformulujte své poznatky ze čtení. K čemu jsou tyto metody dobré? Kdy je která metoda vhodná? Co mi v článku připadá silné a co slabé? Co stále ještě nechápu? Alespoň 5 bodů.

- Kd-stromy strácajú efektivitu so zvyšujúcou sa dimenzionalitou – v praxi začínajú byť problematické už pri desiatkach dimenzií (tzv. *curse of dimensionality*). Ak však majú dáta silné korelácie alebo nízku vnútornú (intrinsic) dimenzionalitu, môžu fungovať dobre aj vo vyšších dimenziách.
- Pri konštrukcii (najmä pri randomized kd-trees) sa ako kandidátna dimenzia vyberá z rozmerov s najväčším rozptylom. V článku sa najprv vyberie niekoľko dimenzií s najväčším rozptylom (autori používajú ($D = 5$)) a z nich sa jedna vyberie náhodne.
- Hlavné parametre pre randomized kd-trees sú počet stromov a počet kontrolovaných listových uzlov (leaf checks) počas vyhľadávania. Počet stromov zvyšuje pravdepodobnosť nájdenia správneho suseda (a zvyšuje aj pamäťové nároky), zatiaľ čo počet kontrolovaných listov ovplyvňuje presnosť výsledku. Pri k-means tree sú hlavné parametre branching factor a počet iterácií algoritmu k-means.
- Hierarchický k-means strom sa buduje rekurzívnym aplikovaním k-means. Autori pri vyhľadávaní používajú prístup best-bin-first, teda prioritnú frontu, do ktorej ukladajú nenavštívené vetvy zoradené podľa vzdialenosti ich centra od dotazového bodu.
- Hierarchický k-means strom môže dosahovať lepší výkon pri veľmi vysokej požadovanej presnosti alebo pri určitých typoch dát, zatiaľ čo randomized kd-trees bývajú výhodnejšie pre mnohé iné datasety. Výkon závisí najmä od štruktúry dát a ich vnútornej dimenzionality.
- Zrýchlenie vyhľadávania je väčšie vtedy, keď môžeme akceptovať nižšiu presnosť výsledkov. Pri menšej požadovanej presnosti je možné dosiahnuť výrazné zrýchlenie.
- Silná stránka článku: praktický prístup: autori porovnávajú viac algoritmov na reálnych datasetoch a navrhujú automatické ladenie parametrov pomocou optimalizácie, ktorá zohľadňuje čas vyhľadávania, čas konštrukcie stromu, aj pamäťové nároky.

Kontrolní otázky

Stručně odpovězte na kontrolní otázky uvedené na Wiki stránce.

1. Co je to problém hledání intervalů (Range Searching) a jaké má praktické využití?
 - a. Majme množinu bodů v d -rozměrném prostoru; problém spočívá v předspracování a uložení těchto bodů tak, aby při zadání rozsahu (např. osovo zarovnaný obdélník) vedel algoritmus rychle vrátit všechny body, které v něm leží. Praktické využití: GIS/přestorové dotazy, databázové intervalové dotazy (časové alebo číselné intervaly), kolízie v počítačovej grafike, vyhľadávanie „features“ v počítačovom videní, indexovanie multidimenzionálnych dát.
2. Jaké výhody má datová struktura Skip Tree a jak se do ní vkládá nová hodnota/uzel?
 - a. Výhody: jednoduchá implementácia, dynamická (efektívne insert/delete), očakávaný čas operácií $O(\log(n))$ bez zložitých rebalansovacích pravidiel. zmena je lokálna (umožňuje ľahšie paralelné operácie).
 - b. Vkládanie: vloží sa nový uzol do spodnej úrovne (level 0) v správnom poradí, náhodnými pokusmi (coin-flips) sa určí výška „veže“ daného prvku, vytvoria sa kópie na vyšších úrovniach a prepoja sa horizontálne s existujúcimi uzlami. Operácia mení len miestne ukazatele.
3. Jak probíhá tvorba kd-tree?
 - a. Rekurzívne: v každom kroku sa vyberie os (v základnej verzii sa striedajú; v praxi sa často zvolí os s najväčším rozptylom) a zlomia sa body podľa mediánu v danej osi na ľavú a pravú podmnožinu, kde pre každú podmnožinu sa postup opakuje. Listy obsahujú jednotlivé body alebo malé množiny bodov. Stavba stromu má typicky zložitost $O(n \cdot \log(n))$ (kvôli hľadaniu mediánov).
4. Jak lze definovat tzv. Approximate Nearest Neighbors Search?
 - a. Ide o hľadanie približného najbližšieho suseda bodu v n -rozměrném prostoru. Algoritmus nemusí nájsť presne najbližší bod, ale bod, ktorého vzdialenosť je veľmi blízka vzdialenosti skutočného najbližšieho suseda. Výhodou je výrazne rýchlejšie vyhľadávanie, najmä pri dátach s vysokou dimenzionalitou.
5. Jaké dvě základní datové struktury pro ANN search používá knihovna FLANN?
 - a. Randomized kd-tree
 - b. Hierarchický k-means tree

Doporučení pro budoucí čtení

Co vám vyhovovalo a co nevyhovovalo na čtení? Přineslo vám čtení něco pozitivního? Které prvky by měly být zachovány, zesíleny, potlačeny, eliminovány? Alespoň jeden bod.

- GNAT tree: ako funguje, výhody a nevýhody.